

UNIVERSITE DE MONTPELLIER
RAPPORT DE PROJET

Claims checking

Belkassim BOUZIDI
Chakib ELHOUITI
Massili KEZZOUL
Abdelkader Nedjari
Ramzi ZEROUAL

Encadrante :
Mr Konstantin TODOROV



UNIVERSITÉ
DE MONTPELLIER



9 mai 2020

Remerciements

Tout d'abord nous souhaitons adresser nos remerciements au corps professoral et administratif de la faculté des sciences de Montpellier qui déploient des efforts pour assurer à leurs étudiants une formation actualisée.

En second lieu, nous tenons à remercier notre encadrante M^{me} pour ses précieux conseils et son aide durant toute la période du travail.

Nos vifs remerciements vont également aux membres du jury pour l'intérêt qu'ils ont porté à notre projet en acceptant d'examiner notre travail.

Nous remercions M^r Yahia Zeroual pour sa relecture attentive de ce rapport.

Table des matières

1	Organisation du projet	3
1.1	Méthodes d'organisation	3
1.2	Decoupage du projet	3
1.2.1	Phase de modélisation	3
1.2.2	Phase de développement	3
1.2.3	Finalisation du projet	3
1.3	Outils de collaboration	4
2	Introduction au sujet	5
2.1	Fact-checking	5
2.1.1	Présentation du principe de fact-checking	5
2.1.2	Présentation de ClaimsKG	5
2.1.3	Travail à réaliser	5
2.2	Technologies utilisées	6
3	conception Modélisation implementation	7
3.1	conception	7
3.2	Implémentation	7
4	Analyse des résultats	8
4.1	résultats	8
4.2	Problèmes rencotrés	8
5	Bilan et conclusions	9
6	Bibliographie et annexes	10

Chapitre 1

Organisation du projet

1.1 Méthodes d'organisation

Afin de mener à bien le développement du projet, nous avons décidé de travailler un maximum de temps ensemble et de manière très régulière. Nous nous sommes réunis trois à quatre fois par semaine, en vue de faire le point sur l'avancement du projet et de définir les objectifs restant à atteindre.

Ainsi, selon l'état de progression de la conception du moteur de requêtes, nous réalisâmes les tâches en retard durant le week-end pour ne pas cumuler de retard et respecter l'intégralité du cahier des charges.

Toutes les semaines, nous nous sommes réunis avec notre encadrant, M^r Konstantin TODOROV. Lors de ces réunions, des mises au point relatives au projet, nous furent prodiguées, cela nous a permis de bénéficier de précieux conseils.

1.2 Decoupage du projet

Nous avons découpé la réalisation du projet en trois grandes phases.

1.2.1 Phase de modélisation

Durant cette étape, nous nous sommes réunis pour définir les fonctionnalités demandées par le projet. Notamment séparer les fonctionnalités importantes de celle moins importantes. Nous avons également choisi les outils de travail collaboratifs et les principales technologies utilisées, ainsi qu'une première modélisation du projet.

1.2.2 Phase de développement

Durant cette phase, nous avons commencé à implémenter les différentes fonctionnalités que nous avons modélisées lors de l'étape précédente, tout en améliorant la modélisation au fur et à mesure de l'avancement de notre projet. Nous avons notamment réalisé des tests pour les différents modules afin de s'assurer de leur bon fonctionnement.

1.2.3 Finalisation du projet

Cette étape a consisté en la réalisation des tests finaux afin de s'assurer que les différents scripts fonctionnent en toute circonstance et éventuellement corriger les bogues qui peuvent apparaître.

1.3 Outils de collaboration

Afin de s'organiser, nous avons décidé d'utiliser Git au travers du serveur GitLab hébergé par le service informatique de la faculté. En effet le logiciel libre Git a facilité grandement la collaboration entre nous. Le serveur GitLab quant à lui est fourni gratuitement par le service informatique de la faculté.

En ce qui concerne la rédaction de ce rapport, nous avons utilisé \LaTeX , système de composition de documents créé par Leslie Lamport, pour faciliter la rédaction à plusieurs.



Schéma 1.1 – Logo du GitLab



Schéma 1.2 – Logo de Latex

Chapitre 2

Introduction au sujet

2.1 Fact-checking

2.1.1 Présentation du principe de fact-checking

Le fact-checking ou la vérification des faits, est une technique consistant d'une part à vérifier la véracité des faits et l'exactitude des chiffres présentés dans les médias et les différents réseaux sociaux et les blogues etc... . Cette notion est apparue aux États-Unis dans les années 1990. Mise en pratique par des journalistes d'investigation dans le cadre de leur profession, la méthode s'est démocratisée grâce à des logiciels aidant les particuliers à vérifier les faits.

L'entrée officielle du fact-checking en France date de 1995, quand est créée l'association Acrimed, qui se présente comme « l'observatoire des médias ».

En vue de la prolifération très rapide des informations, il devient de plus en plus important de s'assurer de la véracité des informations qui se trouvent partout sur Internet et autres médias, tant du point de vue de la société que de celui de la recherche. De nombreuses approches récentes dans diverses communautés scientifiques portent sur des problèmes tels que la vérification des faits, la détection de la pertinence ou de point de vue des documents par rapport à des revendications particulières.

2.1.2 Présentation de ClaimsKG

Le LIRMM[1] en collaboration avec 2 équipes allemandes (L3S Hannover et l'institut de sciences sociologiques GESIS à Cologne), a construit et mise à disposition la base de connaissance ClaimsKG[1] qui recueille les informations et méta-données provenant d'un grand nombre de sites journalistiques internationaux de fact checking, tels que Politifact[1] ou Snopes[1]. ClaimsKG est un graphe de connaissances d'assertions annotées et liées qui facilite la création de requêtes structurées sur les assertions, leurs valeurs de vérité (True, Mostly False, etc...), leurs auteurs, date de publication, etc. ClaimsKG est généré par un pipeline entièrement automatisé qui collecte des assertions et des métadonnées à partir des sites de fact-checking, transforme les données en graphes de connaissances selon un modèle établi, et annote les assertions avec des entités DBpedia (Wikipedia). La base actuelle comprend plus de 32,000 assertions publiées depuis 1996 et est mise à jour régulièrement.

2.1.3 Travail à réaliser

Le sujet du TER consiste en l'enrichissement de cette base de connaissances avec des nouvelles données provenant des sites web suivants :

Fatabyyano[1] Jordani, en Arabe, Fatabyyano (veut dire "Alors montrez-le" en arabe) est la première et la seule plateforme arabe certifiée par l'IFCN [1] ;

Vishvas.news[1] Un site Internet de vérification des faits multilingue (en hindi, anglais ...) qui s'engage à combattre la désinformation et les informations erronées.

Le but du TER sera d'identifier les assertions individuelles dans chaque histoire, ainsi que leur label de véracité et par la suite identifier les relations entre les assertions dans chaque histoire, ainsi que les relations entre ces histoires. Les données produites par ce projet seront intégrées à la base de connaissance ClaimsKG.

La principale difficulté qu'on s'attend à rencontrer est la gestion des différentes langues proposée par ces sites web. Notamment dans l'identification des différentes relations entre les assertions. En effet afin de reconnaître les différents mots-clés du sujet traité par les articles, on utilise habituellement TAGME. un puissant outil de reconnaissance d'entités nommées dans un texte. Les langues utilisées par ces sites web ne sont pas prises en charge par TAGME. Il s'agit donc de trouver une alternative afin de reconnaître ses différentes assertions. Ce problème ainsi que sa résolution sera détaillé plus tard dans ce rapport.

2.2 Technologies utilisées

Nous avons implémenter l'application en Python[1]. Choix qui s'impose de lui même car couplé à la bibliothèque BeautifulSoup[1] il devient très facile de faire du web Scraping[1].

En ce qui concerne la traduction nous avons choisi d'utiliser Yandex Translator[1]. En effet en vu de la taille des données à traduire nous avons pas pu utiliser l'api de traduction de Google puisque cette dernière devient payante à partir d'un certain nombre de caractères.

En fin, la reconnaissance des différents entités concerné est faite grace à l'outil TAGME[1] a travers son API python[1].

Chapitre 3

conception Modélisation implementation

3.1 conception

3.2 Implémentation

Chapitre 4

Analyse des résultats

4.1 résultats

4.2 Problèmes rencontrés

Chapitre 5

Bilan et conclusions

Chapitre 6

Bibliographie et annexes